



Universidad de Buenos Aires
Facultad de Ciencias Económicas
Escuela de Estudios de Posgrado



CLASIFICANDO DE POBRES CON LA EPH

Maestría: Economía Aplicada Materia: Taller de Programación

Profesor: Romero, María Noelia

Alumnos: Godino, Franco; Sulca, Ronny; y Alvarez, Martín

Año 2025

Enlace al repositorio: <https://github.com/alvarezmartin2411-debug/Big-Data-UBA--Grupo-2/tree/main>

Introducción


El presente informe tiene por objetivo evaluar el desempeño predictivo de distintos modelos de clasificación aplicados a la identificación de hogares pobres en Argentina utilizando la base de la EPH para el año 2025. Sobre la matriz de predictores construida en el TP3, que incluye variables sociodemográficas y económicas seleccionadas por su relevancia teórica y empírica, se implementan técnicas de regularización (LASSO y Ridge), modelos de árboles de decisión podados mediante complejidad de costos y se comparan sus resultados con los modelos benchmark del TP3: Logit sin penalidad y KNN con validación cruzada. El análisis se centra tanto en la capacidad predictiva fuera de la muestra como en la interpretación económica de los coeficientes y la importancia de las variables, evaluando métricas como accuracy, recall, F1 y AUC.

A. Modelo de Regresión Logística con Regularización: Ridge y LASSO

PARTE A1



En primer lugar, se muestra en el Gráfico 1 los coeficientes de Lasso y Ridge. Para la regresión Lasso se observa que para los valores bajos de λ , los coeficientes toman valores relativamente grandes, similares a un logit casi sin regularización y a medida que λ aumenta, las trayectorias de los coeficientes se encogen rápidamente hacia cero. Por otro lado, para la regresión Ridge, conforme aumenta λ , todos los coeficientes se reducen de forma suave y continua, acercándose a cero, pero sin volverse exactamente cero. Este primer resultado es lo esperado cuando se aplica un efecto de regularización.

Gráfico 1: Coeficientes LASSO y Ridge.



PARTE A2

Usando LogisticRegressionCV con validación cruzada 5-fold y la grilla $\lambda = 10^n$, $n \in \{-5, \dots, 5\}$, se obtuvo que la penalidad óptima fue $\lambda_{L1}^{cv} = 0,1$ para LASSO y $\lambda_{L2}^{cv} = 10^{-5}$ para Ridge. El gráfico del error de clasificación promedio ($1 - \text{accuracy}$) muestra que, para valores pequeños de λ (débil regularización), el error se mantiene relativamente bajo y estable ($\approx 0,33$) en ambos métodos. Sin embargo, al incrementar λ , el error aumenta de manera clara, especialmente en el caso de LASSO, lo que indica que una penalización excesiva “sobresimplifica” el modelo y deteriora su capacidad predictiva. En el Gráfico 2.B muestra la proporción de variables ignoradas (coeficientes ≈ 0) en función de λ , lo cual confirma el resultado anteriormente escrito.

Gráfico 2.A: Error de clasificación**Gráfico 2.B: Proporción de coeficientes**

PARTE A3

En la Tabla 1 se comparan los coeficientes del modelo logit sin penalidad con los de las versiones regularizadas L1 (LASSO) y L2 (Ridge), usando la penalidad óptima λ^{cv} . El signo y el orden de importancia de las variables se mantiene prácticamente igual en las tres

especificaciones. Por ejemplo, *estado* sigue siendo la variable con efecto negativo más fuerte: pasa de $-0,883$ (sin penalidad) a $-0,873$ en LASSO y $-0,886$ en Ridge. De forma similar, *pp03i* conserva un efecto negativo importante ($\approx -0,61$) y *pp10a* un efecto positivo moderado ($\approx 0,32$) en los tres modelos.

Las diferencias entre columnas son muy pequeñas y reflejan solo un ligero encogimiento (shrinkage) de los coeficientes. Por ejemplo, el intercepto pasa de 1,290 a 1,209 en LASSO y 1,293 en Ridge, mientras que *cat_ocup* va de $-0,128$ a $-0,125$ y $-0,128$, respectivamente. En ningún caso los coeficientes se vuelven exactamente cero, por lo que la penalidad L2 no elimina variables de X_{train} , con la λ^{cv} encontrada, tanto L1 como L2 actúan más como una regularización suave que como un mecanismo de selección de variables.


Tabla 1: Tabla de resultados

Variable	Logit_sin_penalidad	LASSO_L1	Ridge_L2
intercept	1.289704	1.209223	1.293019
pp10a	0.317499	0.316957	0.314689
ad_equiv_hogar	0.301822	0.302184	0.302048
cat_inac	0.236533	0.235769	0.236678
ch04	0.149859	0.151233	0.150585
ch06	-0.025505	-0.025393	-0.025507
ch07	-0.084899	-0.084361	-0.084619
cat_ocup	-0.128158	-0.124631	-0.1279
nivel_ed	-0.189428	-0.188976	-0.189137
pp03i	-0.608043	-0.604104	-0.612296
estado	-0.882597	-0.87334	-0.886127

B. Árboles de Decisión

PARTE B4



Para seleccionar el parámetro de complejidad *ccp_alpha* del árbol de decisión se utilizó validación cruzada 10-fold sobre una grilla de valores obtenida a partir de la función *cost_complexity_pruning_path*. Luego del filtrado se trabajó con 504 valores de *ccp_alpha* estrictamente positivos y menores a 0,05 (por ejemplo, los primeros son $1,10 \times 10^{-5}$, $1,64 \times 10^{-5}$, $1,83 \times 10^{-5}$, etc.). El mejor valor según la accuracy promedio de CV fue $ccp_alpha^{cv} \approx 0,0004225$.

Gráfico 3: Error de clasificación

El gráfico del error de clasificación promedio ($1 - \text{accuracy}$) en función de ccp_alpha muestra una curva con forma de “U”. Para valores muy pequeños de ccp_alpha el error es relativamente alto ($\approx 0,37$), indicando un árbol poco podado y con riesgo de sobreajuste. A medida que aumentamos ligeramente la complejidad penalizada, el error disminuye hasta un mínimo alrededor de ccp_alpha^{cv} , donde se alcanza el mejor compromiso entre sesgo y varianza. A partir de ese punto, cuando ccp_alpha sigue creciendo, el árbol se poda en exceso y el error vuelve a incrementarse de manera constante (superando el 0,40 para valores cercanos a 0,04). Esto sugiere que el árbol óptimo es uno moderadamente podado, que reduce el sobreajuste sin simplificar en exceso la estructura.

PARTE B5

En el Gráfico 4 se muestra el árbol de decisión podado estimado con el ccp_alpha^{cv} seleccionado por validación cruzada. El nodo raíz utiliza la variable `ad_equiv_hogar` como primer criterio de partición, separando a los hogares según su ingreso equivalente per cápita y distinguiendo grandes grupos de “No pobres” y “Pobres”. A partir de allí, los siguientes niveles combinan principalmente las variables `ch06` (edad) y `nivel_ed` (nivel educativo), junto con `pp03i` (ingresos laborales), para refinar la clasificación. En conjunto, la estructura del árbol refleja que la probabilidad de pobreza se explica sobre todo por el ingreso equivalente del hogar, la edad y la educación del jefe, mientras que otras variables solo aparecen en ramas más profundas o no son utilizadas para hacer particiones.

Gráfico 4: Árbol de decisión podado (CART con ccp_alpha óptimo)**Gráfico 5: Importancia de predictores en el árbol podado**

El Gráfico 5 se resume esta información mediante la importancia de variables del árbol podado. La variable `ad_equiv_hogar` concentra más de la mitad de la importancia total ($\approx 0,52$), seguida por `ch06` ($\approx 0,19$) y `nivel_ed` ($\approx 0,14$); luego aparecen `pp03i` ($\approx 0,12$), `ch07` y `cat_ocup` con importancias ya mucho menores, mientras que variables como `cat_inac`, `pp10a` y otras tienen un aporte casi residual. Esto confirma que el árbol se apoya fuertemente en unas pocas variables clave para decidir los cortes principales.

Al comparar estas importancias con el modelo LASSO, es importante notar que, con la penalidad óptima $\lambda_{L1}^{cv} = 0,1$, ningún coeficiente fue reducido exactamente a cero: todas las variables de X_{train} mantienen coeficientes distintos de cero, solo ligeramente “encogidos” respecto al logit sin penalidad. Por lo tanto, en nuestro ejercicio no puede afirmarse que las variables menos importantes en el árbol sean aquellas que LASSO “achicó” a cero, porque LASSO no eliminó variables y, además, la importancia en un árbol CART (basada en reducción de impureza) no es directamente equivalente al tamaño del coeficiente en una regresión logística penalizada.

C. Comparación entre métodos

PARTE C6

En términos de performance predictiva, las diferencias entre modelos son relativamente pequeñas. El logit sin penalidad tiene una accuracy de 0,656 (error $1 - \text{accuracy} \approx 0,344$), LASSO y Ridge prácticamente repiten ese desempeño (errores $\approx 0,346$ y $\approx 0,344$), KNN mejora mínimamente (error $\approx 0,343$) y el árbol podado es el mejor, con accuracy de 0,662 y un error de solo $1 - \text{accuracy} \approx 0,338$. Es decir, el mejor método no lineal reduce el error de clasificación en alrededor de 0,6 puntos porcentuales respecto al logit base y además logra el mayor *recall* (0,602), lo que puede ser valioso si la prioridad del Ministerio es identificar la mayor cantidad posible de hogares pobres.

Gráfico 6: Curvas ROC




Tabla 2: Tabla de resultados

Modelos	Accuracy	Precision	Recall	F1
Logit sin penalidad	0.655807	0.633588	0.563667	0.596586
LASSO	0.65389	0.631328	0.561121	0.594157
Ridge	0.655807	0.633588	0.563667	0.596586
KNN (K-CV)	0.656573	0.628885	0.584041	0.605634
Árbol podado	0.661939	0.631907	0.601868	0.616522

Sin embargo, esa ganancia en desempeño viene con un costo de comunicación. Las regresiones logísticas (sin penalidad, LASSO y Ridge) son mucho más sencillas de explicar: cada coeficiente se interpreta como el efecto de una variable sobre la probabilidad de pobreza, lo que permite construir mensajes claros para tomadores de decisión. El árbol podado, aunque visual, es grande y difícil de resumir en reglas simples; KNN directamente es una “caja negra” que no genera parámetros interpretables. Dado que el aumento en performance de los métodos no lineales es moderado (el error baja de $\approx 0,344$ a $\approx 0,338$), la ventaja predictiva de usar un método no lineal existe pero es acotada, y debe sopesarse contra la necesidad de contar con modelos transparentes y fácilmente comunicables.

PARTE C7

Si cambia nuestra respuesta. Para el objetivo del Ministerio la métrica clave es el Recall (minimizar falsos negativos). En el set de test, el árbol podado es el modelo con mejor recall (0,602) y al mismo tiempo el de menor error de clasificación ($1 - \text{accuracy} = 1 - 0,6619 \approx 0,338$). Esto mejora tanto al logit sin penalidad (recall 0,564; error $\approx 0,344$) como al KNN (recall 0,584; error $\approx 0,343$).

Además, a diferencia de KNN, el árbol ofrece reglas explícitas (“si ingreso equivalente $\leq X$ y nivel educativo $\leq Y$, entonces clasificar como pobre”) que pueden comunicarse razonablemente bien a los decisores. Por tanto, considerando desempeño predictivo orientado al recall y posibilidad de explicar las reglas de asignación, el árbol de decisión podado pasa a ser el “mejor” modelo.